CIENCIA DE DATOS | ANALÍTICA FINANCIERA

Predicción de la morosidad bancaria en Ecuador

Modelos de aprendizaje automático, validación temporal y trazabilidad con MLflow

23
instituciones

5.972
registros banco-mes

8,19 %
mejora del MAE a 1 mes

Gustavo Paredes

Informe de investigación aplicada · Octubre de 2026

https://github.com/tavomx45/audit-ecuador-banking-data

Resumen ejecutivo

Pregunta de investigación. ¿La información financiera histórica permite pronosticar la morosidad mensual de bancos privados ecuatorianos mejor que una estrategia de referencia sencilla, sin introducir información futura en el entrenamiento?

Se desarrolló un flujo completo de aprendizaje supervisado con información de la Superintendencia de Bancos del Ecuador. El panel cubre **23 instituciones**, **5.972 registros banco-mes** y el período enero de 2003 a septiembre de 2026. El diseño experimental combina análisis exploratorio, ingeniería de características, cinco particiones de validación temporal, comparación de modelos, ablaciones, optimización y evaluación final independiente.

El sistema seleccionado es **híbrido**: Random Forest entrenado para pronosticar el cambio de morosidad a un mes y persistencia con ajuste estacional para los horizontes de dos y tres meses. En el conjunto de prueba, Random Forest obtuvo un **MAE de 0,2839 puntos porcentuales** a un mes, frente a 0,3092 para la referencia estacional: **8,19 % menos error**.

Horizonte	Muestras	MAE (pp)	RMSE (pp)	R^2
1 mes	276	**0,2839**	0,4765	0,9590
2 meses	253	0,3902	0,6937	0,9111
3 meses	230	0,4636	0,8031	0,8798

La investigación distingue precisión de nivel y capacidad de alerta. A un mes, el modelo detectó únicamente **5 de 23** incrementos reales de al menos 0,5 pp (recall de **21,7 %**). Por tanto, los resultados respaldan su utilidad como **prototipo de pronóstico retrospectivo**, no su uso autónomo para alertas prudenciales.

Límite operativo principal. El corte temporal evita que se ajusten modelos con etiquetas futuras, pero aún no modela explícitamente la fecha de *publicación efectiva* de cada indicador bancario. Los resultados no equivalen a una simulación auditada de disponibilidad de datos en tiempo real.

Índice

1. Contexto y objetivo **4**

1.1. Alcance y contribuciones 4

2. Datos y auditoría financiera **4**

2.1. Origen y estructura 4

2.2. Controles de calidad y casos especiales 4

3. Exploración: distribución, heterogeneidad y tiempo **5**

3.1. Distribución de la morosidad 5

3.2. Variabilidad institucional 5

3.3. Trayectorias y posibles patrones estacionales 6

4. Ingeniería de características **7**

5. Protocolo de validación temporal **8**

5.1. Desarrollo y cinco folds cronológicos 8

5.2. Corte de entrenamiento seguro y prueba independiente 8

6. Modelos, formulaciones y elección de estrategia **9**

6.1. Referencias estadísticas 9

6.2. Predicción directa y predicción del cambio 9

6.3. Regularización, ablaciones y optimización 9

6.4. Selección final por horizonte 10

7. Evaluación final independiente **11**

7.1. Errores por horizonte 11

7.2. Análisis temporal del desempeño 11

7.3. Análisis institucional 12

8. ¿Sirve como alerta temprana? **13**

8.1. Error según la dirección del cambio 13

8.2. Detección de incrementos sustanciales 13

9. Trazabilidad, software e inferencia **14**

9.1. Implementación modular y pruebas 14

9.2. MLflow y serialización 14

10. Limitaciones y trabajos futuros **15**

11. Conclusiones **15**

Fuentes y documentación **15**

A. Procedencia de las figuras **16**

1 Contexto y objetivo

La morosidad de la cartera de crédito es un indicador de la calidad de los activos bancarios. Su evolución puede reflejar cambios en el perfil de los prestatarios, la composición de cartera y las condiciones económicas. Este proyecto estudia una tarea delimitada: *pronosticar el porcentaje de cartera improductiva de cada institución*, no estimar el incumplimiento de clientes particulares ni elaborar calificaciones regulatorias.

Para una institución b, un mes de origen t y un horizonte $h \in \{1, 2, 3\}$:

$$\widehat{M}_{b,t+h} = f_h(\mathbf{X}_{b,t}), \qquad M_{b,t} = 100\frac{\text{cartera improductiva}_{b,t}}{\text{cartera bruta}_{b,t}}. \tag{1}$$

El objetivo central es comparar familias de aprendizaje supervisado frente a referencias estadísticas bajo una validación que respete la cronología y que priorice el error absoluto medio (MAE) en puntos porcentuales.

1.1 Alcance y contribuciones

- Panel de datos bancarios con verificaciones de integridad financiera y temporal.
- Características dinámicas, financieras y de calendario, construidas por banco.
- Cinco folds cronológicos compartidos entre instituciones.
- Comparación de modelos directos y formulaciones de pronóstico por diferencias.
- Selección de estrategia por horizonte, diagnóstico de fallos y registro en MLflow.
- Interfaz modular de inferencia, pruebas automatizadas y artefactos serializados.

2 Datos y auditoría financiera

2.1 Origen y estructura

Los datos proceden de boletines mensuales de la Superintendencia de Bancos del Ecuador, especialmente indicadores financieros y componentes de cartera. El proceso de extracción unificó nombres institucionales, fechas y unidades; el resultado es un **panel desbalanceado** porque no todos los bancos tienen cobertura en todos los meses.

Cuadro 1: Resumen del panel histórico utilizado en el proyecto.

Instituciones	23 bancos privados
Observaciones	5.972 registros banco–mes
Período	enero de 2003 – septiembre de 2026
Frecuencia	mensual
Objetivo	morosidad total por banco, expresada en %
Panel	desbalanceado

2.2 Controles de calidad y casos especiales

El notebook de auditoría explora duplicados banco–mes, coherencia entre cartera improductiva y bruta, datos faltantes y discontinuidades. En el análisis exploratorio se reportan **5.966 observaciones de morosidad verificables** entre 5.972 registros; los seis casos no verificables se asocian a Delbank y valores de cartera bruta nulos. Se documentan también valores faltantes de otros indicadores, sin imputar indiscriminadamente observaciones financieras dudosas.

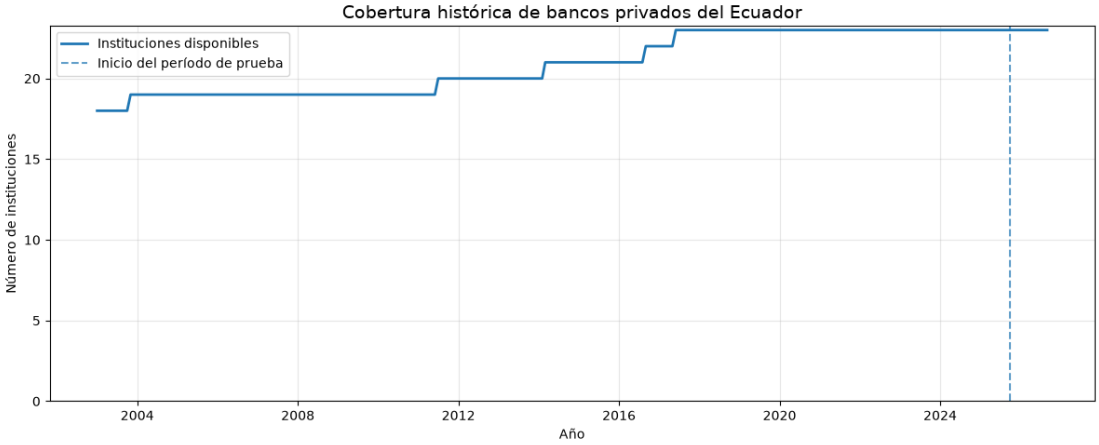


Figura 1: Cobertura histórica institucional. La muestra aumenta desde 18 entidades en 2003 hasta 23 en los años posteriores. Fuente: notebook de análisis exploratorio.

Decisión de preparación. Conservar los registros históricos y representar valores no verificables como faltantes, en lugar de reemplazar valores económicamente sensibles por cifras fabricadas o eliminar instituciones completas.

3 Exploración: distribución, heterogeneidad y tiempo

3.1 Distribución de la morosidad

El EDA encontró una distribución **asimétrica a la derecha**: media histórica de **4,84 %**, mediana de **3,62 %** y máximos de hasta **87,04 %**. Este comportamiento favorece métricas basadas en el error absoluto y exige inspeccionar las instituciones responsables de variaciones extremas.

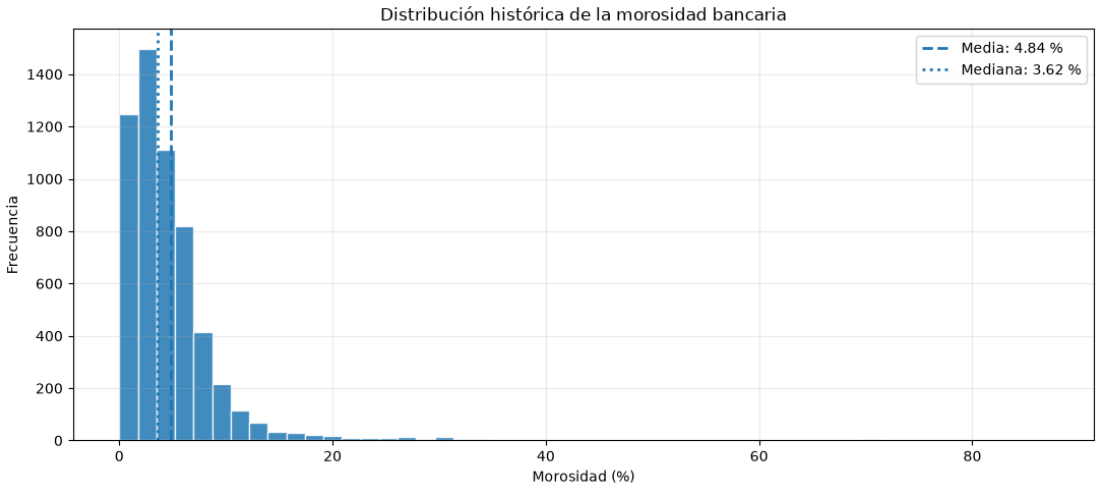
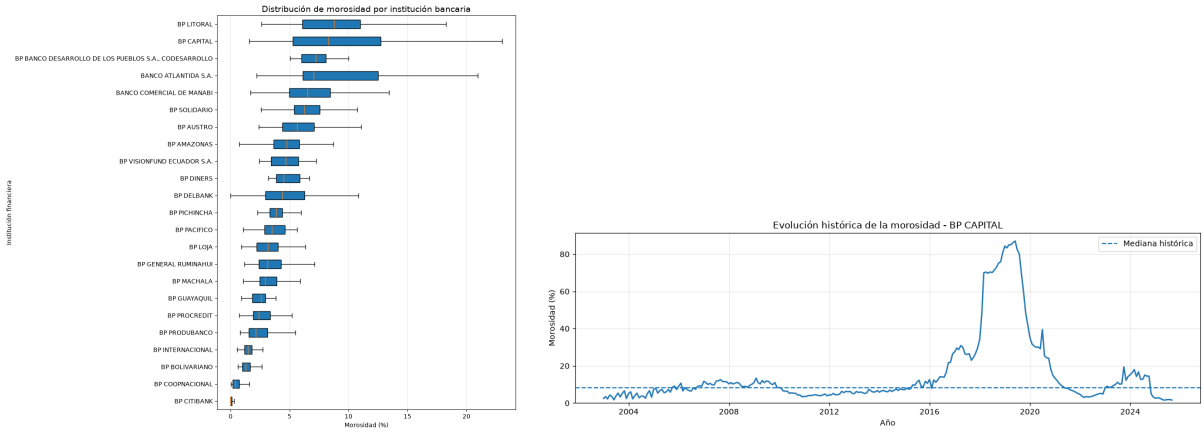


Figura 2: Histograma de morosidad del conjunto histórico de desarrollo. La cola derecha indica episodios poco frecuentes de niveles muy elevados. Fuente: notebook de EDA.

3.2 Variabilidad institucional

Los niveles y dispersiones varían significativamente entre bancos. En particular, **BP Capital** concentró un episodio de morosidad muy elevada alrededor de 2018–2019; el notebook documenta un máximo de **87,04 % en junio de 2019**. Este caso motiva análisis de errores por institución

y experimentos que midan la sensibilidad a observaciones extremas.



(a) Distribución por banco. **(b)** Evolución histórica de BP Capital.

Figura 3: Heterogeneidad entre instituciones y presencia de episodios extremos. Ambas visualizaciones proceden del notebook de EDA.

3.3 Trayectorias y posibles patrones estacionales

La evolución agregada de la morosidad depende del criterio de ponderación. El notebook compara la media institucional y una medida ponderada por cartera, que difieren en el tiempo. Esto refuerza la importancia de definir la unidad de análisis: aquí cada *observación banco–mes* es una unidad predictiva.

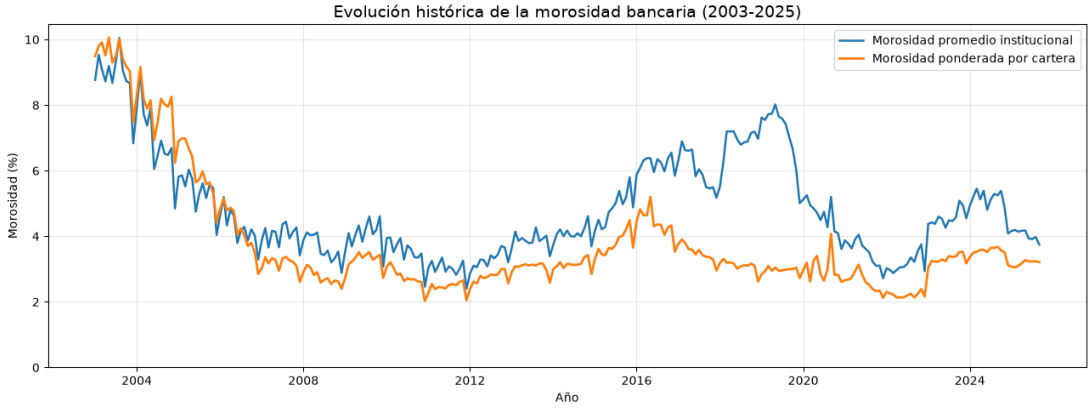


Figura 4: Evolución histórica: media de instituciones frente a morosidad ponderada por cartera. La figura refleja diferencias de agregación, no dos objetivos de entrenamiento. Fuente: notebook de EDA.

El estudio de variaciones mensuales también sugiere diferencias según el mes calendario. La mediana del cambio suele ser pequeña, aunque el patrón difiere entre meses y puede contener efectos de composición. Esta observación justifica evaluar una **persistencia con ajustes estacionales** como baseline formal.

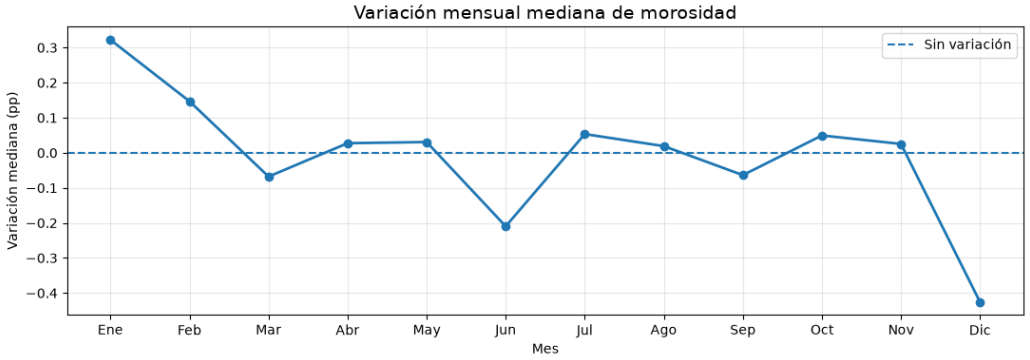


Figura 5: Medianas de cambios mensuales de morosidad por mes calendario. Fuente: notebook de EDA.

4 Ingeniería de características

El notebook `02_feature_engineering` construye objetivos para $h = 1, 2, 3$ mediante asociaciones por banco y por fecha, evitando confundir el desplazamiento de filas con una distancia exacta de meses cuando existen huecos en las series.

La matriz de entrada integra **22 predictores** en el modelo final a un mes: identificador del banco y variables numéricas como morosidad actual y rezagada, cambios recientes, promedios y dispersiones móviles, rentabilidad (ROA, ROE), solvencia, liquidez, crecimiento de cartera y componentes cíclicas de calendario.

La estacionalidad puede codificarse con:

$$\text{mes}_{\sin}(t) = \sin\left(\frac{2\pi m_t}{12}\right), \qquad \text{mes}_{\cos}(t) = \cos\left(\frac{2\pi m_t}{12}\right). \tag{2}$$

Se utilizaron transformaciones logarítmicas cuando correspondía para reducir asimetrías de determinadas variables financieras. Las transformaciones que requieren parámetros aprendidos se integraron en pipelines, de manera que su ajuste no utilizara Test.

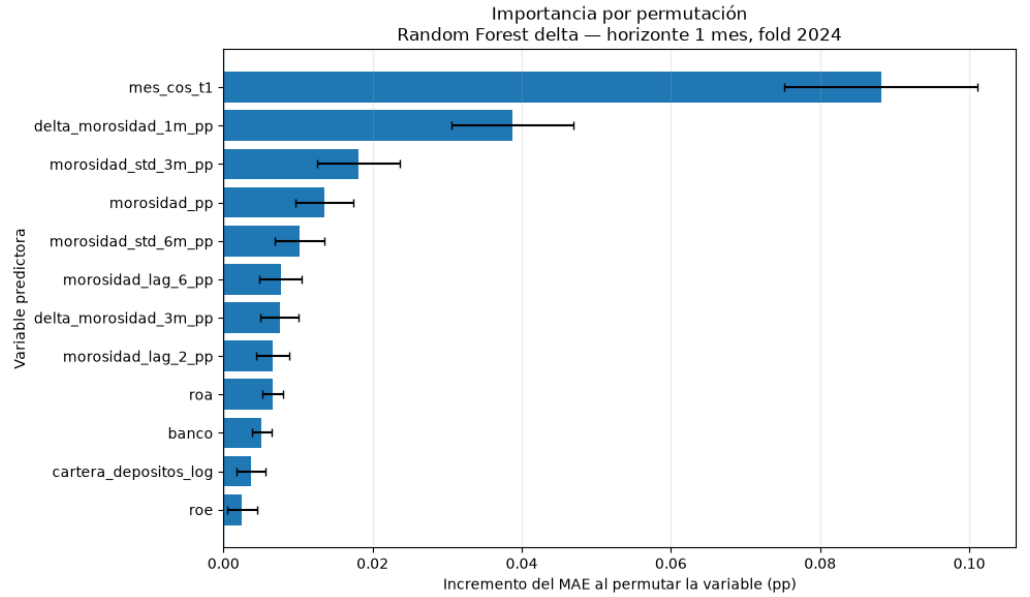


Figura 6: Importancia por permutación de variables para Random Forest delta, en el fold de validación 2024. Diagnóstico local de desarrollo, no interpretación causal ni resultado de Test. Fuente: notebook de experimentos delta.

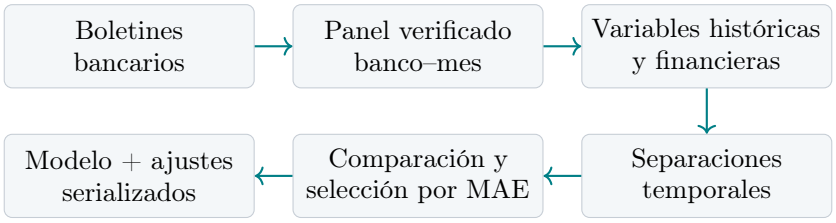


Figura 7: Flujo de trabajo del proyecto, desde las fuentes hasta los artefactos de inferencia. Elaboración propia.

5 Protocolo de validación temporal

5.1 Desarrollo y cinco folds cronológicos

Se evaluaron modelos mediante **cinco cortes de validación temporal**, correspondientes a los años 2021–2025, con entrenamiento de ventana creciente. Todas las entidades comparten las fronteras cronológicas y se comprueba, por fold, que la última *fecha objetivo* observada en el entrenamiento preceda al primer origen de validación.

$$\text{máx}\{\text{fechaobjetivo(train)}\} < \text{mín}\{\text{fechaorigen(validacion)}\}. \tag{3}$$

El criterio principal de selección fue el MAE (puntos porcentuales):

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|M_i - \widehat{M}_i|. \tag{4}$$

También se calcularon RMSE, R^2 y sesgo medio para complementar el diagnóstico.

5.2 Corte de entrenamiento seguro y prueba independiente

Para el cierre de Test se fijaron exclusivamente observaciones cuyo objetivo era anterior al **primer mes de origen de Test (septiembre de 2025)**. El entrenamiento más reciente admitido contiene etiquetas objetivo hasta agosto de 2025.

Cuadro 2: Auditoría temporal previa al Test.

Horizonte	Desarrollo	Train seguro	Excluidas	Test
1 mes	5.666	5.643	23	276
2 meses	5.644	5.621	23	253
3 meses	5.621	5.598	23	230

Los objetivos del conjunto de prueba abarcan octubre de 2025–septiembre de 2026 para el horizonte de un mes; comienzan un mes después en los horizontes superiores. Las predicciones se formularon con orígenes mensuales actualizados y con parámetros del modelo congelados. Este procedimiento no equivale a pronosticar doce meses desde una única fecha de origen.

Límite de disponibilidad. Controlar fechas objetivo y etiquetas de entrenamiento no demuestra que los indicadores del mes t ya estuvieran publicados en el instante de un pronóstico operativo. Una evaluación futura deberá utilizar las fechas efectivas de publicación de cada boletín.

6 Modelos, formulaciones y elección de estrategia

6.1 Referencias estadísticas

La referencia más simple es persistencia: $\widehat{M}_{b,t+h} = M_{b,t}$. La estrategia estacional añade al valor actual una corrección aprendida *solo* con entrenamiento para el mes calendario objetivo:

$$\widehat{M}_{b,t+h} = \text{clip}\left(M_{b,t} + \widehat{c}_{m(t+h)},\, 0,\, 100\right). \tag{5}$$

La existencia de una referencia competitiva es importante: un modelo más complejo debe demostrar una mejora consistente antes de ser seleccionado.

6.2 Predicción directa y predicción del cambio

Se compararon Ridge, Random Forest e HistGradientBoosting con formulación directa y por diferencias (*delta*):

$$\text{Directa:} \quad \widehat{M}_{b,t+h} = f_h(\mathbf{X}_{b,t}), \tag{6}$$

$$\text{Delta:} \quad \widehat{\Delta M}_{b,t+h} = g_h(\mathbf{X}_{b,t}), \tag{7}$$

$$\widehat{M}_{b,t+h} = M_{b,t} + \widehat{\Delta M}_{b,t+h}. \tag{8}$$

La segunda permite entrenar el modelo sobre la variación desde el valor ya conocido; resultó especialmente útil para Random Forest a un mes.

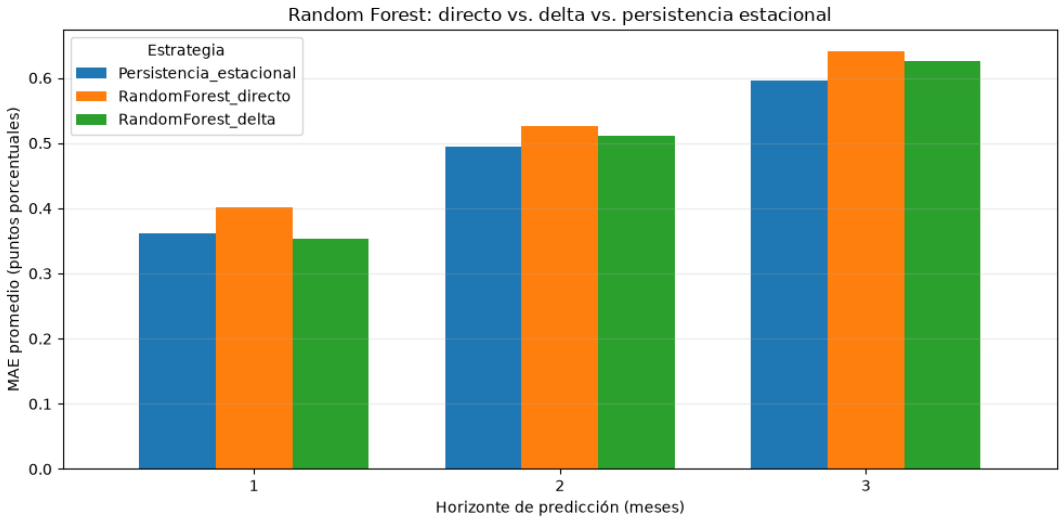


Figura 8: Comparación de Random Forest directo, Random Forest delta y referencia estacional sobre validación temporal. Fuente: notebook de experimentos delta.

6.3 Regularización, ablaciones y optimización

Se inspeccionó la contribución de familias de variables, incluyendo características financieras, dinámica histórica, rezagos y estacionalidad. Las ablaciones muestran que modificar grupos de predictores altera el MAE de manera distinta según horizonte; por ello se evitó seleccionar variables a partir de un solo fold o una mejora localizada en una institución.

El ajuste fino de Random Forest comparó cinco configuraciones (Original, Regularizado, Intermedio, Flexible y Profundo) sobre cinco folds para cada horizonte: **75 evaluaciones configuración–fold**. La estrategia elegida a un mes fue **Flexible**, con `n_estimators=150`, `max_depth=14`, `min_samples_leaf=3`, `max_features=0.7` y semilla 42.

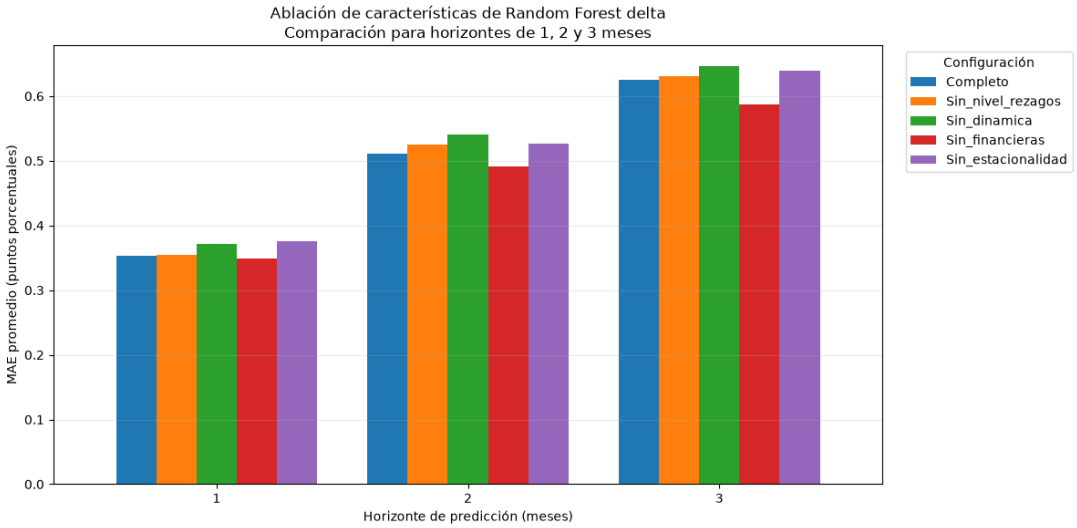


Figura 9: Análisis de ablación multihorizonte de Random Forest delta. Valores de validación cruzada, no métricas del Test final. Fuente: notebook de experimentos delta.

6.4 Selección final por horizonte

Cuadro 3: Comparación temporal del sistema elegido frente a la persistencia estacional.

h	**Estrategia**	**MAE CV**	**DE CV**	**MAE ref.**
1	Random Forest delta flexible	**0,3488**	0,0695	0,3618
2	Persistencia estacional	0,4948	0,0913	0,4948
3	Persistencia estacional	0,5963	0,1058	0,5963

El Random Forest seleccionado ganó en cuatro de cinco folds a un mes. En los horizontes de dos y tres meses, la referencia estacional fue retenida por su mayor robustez respecto a las alternativas evaluadas.

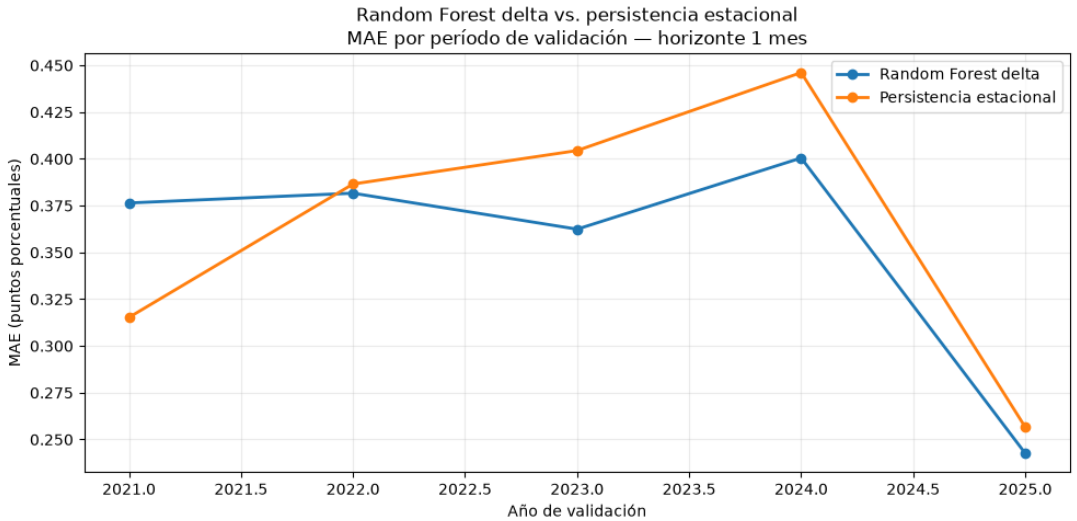


Figura 10: MAE anual en validación temporal: Random Forest delta y referencia estacional a un mes. Figura del período de desarrollo, no del Test. Fuente: notebook de experimentos delta.

7 Evaluación final independiente

7.1 Errores por horizonte

Se calculó una única evaluación final del sistema congelado, con **759 predicciones banco–mes–horizonte**. Para cada horizonte se informan MAE, RMSE y R^2, separados de las métricas de validación cruzada.

Cuadro 4: Resultados finales sobre el conjunto de prueba.

Horizonte	n	MAE (pp)	RMSE (pp)	R^2	MAE ref.
1 mes	276	**0,2839**	0,4765	0,9590	0,3092
2 meses	253	0,3902	0,6937	0,9111	0,3902
3 meses	230	0,4636	0,8031	0,8798	0,4636

A un mes, el error medio del modelo se redujo **8,19 %** respecto de persistencia estacional. A dos y tres meses el valor igual al baseline es esperado: *la persistencia estacional es la estrategia seleccionada*, no un resultado de superioridad sobre sí misma.

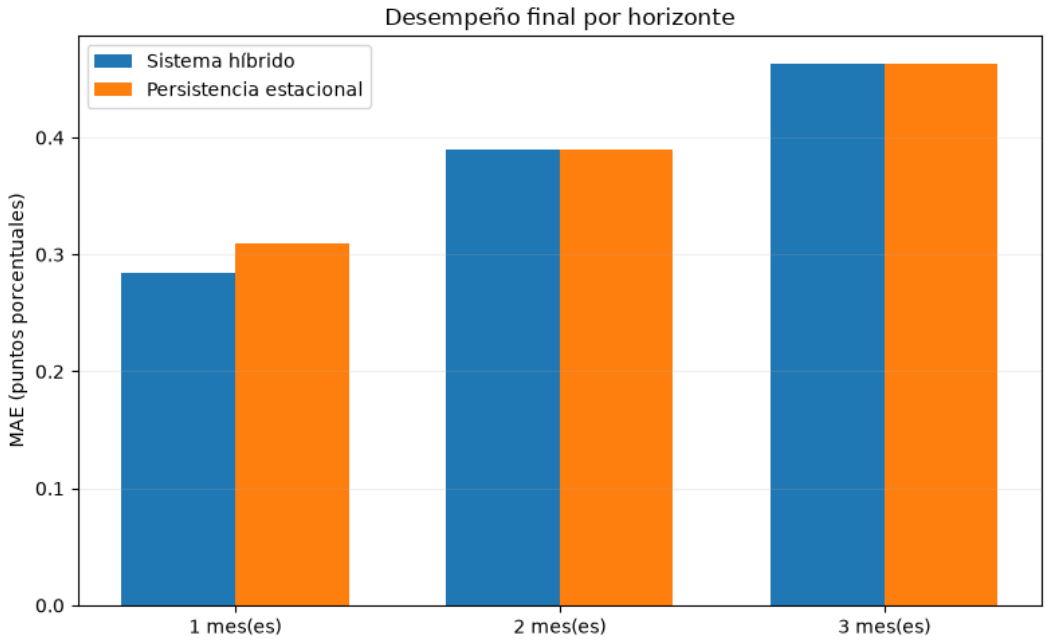


Figura 11: Comparación del MAE final por horizonte entre sistema híbrido y persistencia estacional. Fuente: notebook de experimentos delta, evaluación E8.

Los valores de R^2 altos reflejan buen ajuste de niveles de morosidad en la evaluación agregada; no prueban sensibilidad ante incrementos grandes, particularmente en un panel con diferencias estructurales entre bancos.

7.2 Análisis temporal del desempeño

El Random Forest obtuvo menor error que la referencia en **8 de 12 meses objetivo**. La reducción más notable se registró en diciembre de 2025 (aproximadamente 0,1511 pp); en septiembre de 2026 el modelo fue inferior a la referencia ($-0,0590$ pp de ventaja).

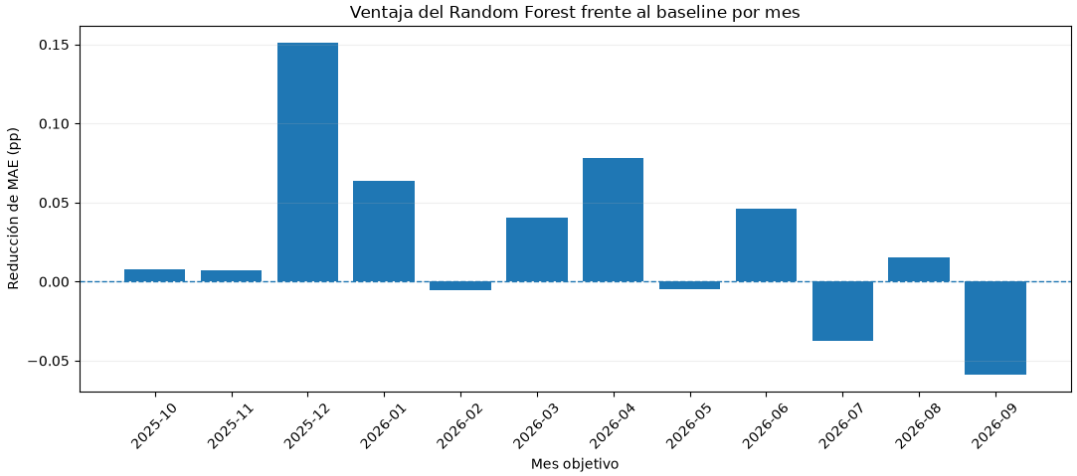


Figura 12: Diferencia de MAE mensual: valores positivos representan mejora de Random Forest a un mes. Período final de Test. Fuente: notebook de experimentos delta.

7.3 Análisis institucional

El modelo mejoró el MAE en **15 de 23 bancos**. No obstante, tres instituciones (BP Litoral, Banco Comercial de Manabí y BP Amazonas) aportaron aproximadamente **92,49 % de la mejora neta acumulada**; la ventaja agregada está, por tanto, concentrada.

Cuadro 5: Instituciones con mayores MAE a un mes en Test.

Institución	MAE RF	MAE estacional
Banco Comercial de Manabí	0,8568	1,0012
BP Delbank	0,7936	0,8633
BP Litoral	0,7698	1,0374
Banco Atlántida S.A.	0,7693	0,6003
BP Amazonas	0,5909	0,7178

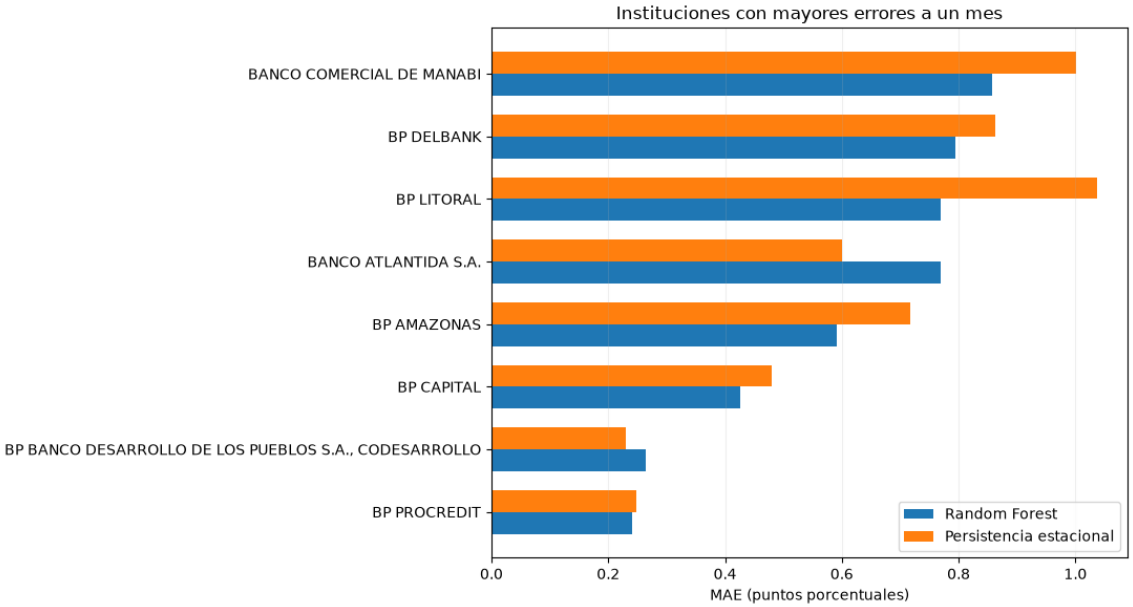


Figura 13: Ocho instituciones con mayores errores a un mes: Random Forest frente a referencia estacional. Fuente: notebook de experimentos delta, Test E8.

8 ¿Sirve como alerta temprana?

8.1 Error según la dirección del cambio

A un mes, los errores se desglosaron según la diferencia real $M_{t+1} - M_t$: aumento de al menos 0,10 pp, disminución de al menos 0,10 pp y variaciones menores en valor absoluto.

Cuadro 6: MAE a un mes, agrupado por la dirección de la variación real.

Categoría	n	MAE RF	MAE ref.
Aumento	78	0,3411	0,4118
Disminución	80	0,4954	0,5113
Estabilidad	118	0,1026	0,1044

8.2 Detección de incrementos sustanciales

Se evaluó si el cambio estimado superaba los mismos umbrales que los incrementos reales de morosidad. Esta comparación es **exploratoria**, no un sistema regulatorio de alarmas.

Cuadro 7: Detección de incrementos importantes a un mes.

Umbral	Eventos	Alertas	TP	Precisión	Recall
$\geq 0,5$ pp	23	8	5	62,5 %	**21,7 %**
$\geq 1,0$ pp	9	3	1	33,3 %	**11,1 %**

El sistema omitió **18 de 23** aumentos de 0,5 pp y **8 de 9** aumentos de 1 pp, a pesar del favorable MAE agregado. El resultado sugiere que los árboles suavizan parte de las variaciones extremas y que optimizar solamente MAE no equivale a optimizar sensibilidad de alerta.

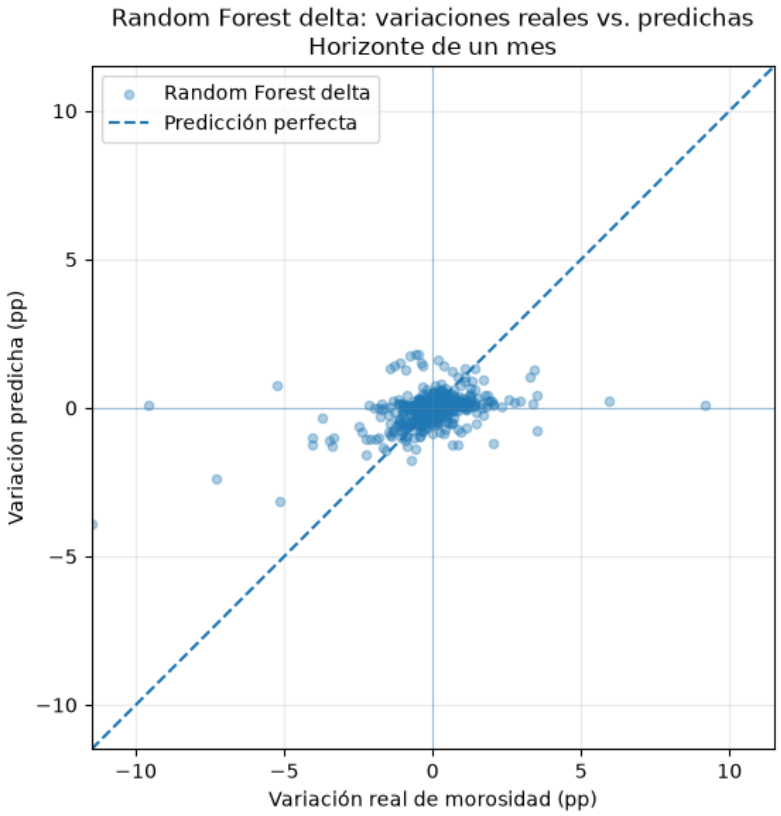


Figura 14: Variaciones reales frente a variaciones estimadas por Random Forest delta en los experimentos de desarrollo. Las predicciones se concentran cerca de cero: evidencia diagnóstica, no gráfica del Test. Fuente: notebook de experimentos delta.

Interpretación. El sistema puede ayudar a estimar niveles futuros como ejercicio de investigación, pero **no ha demostrado sensibilidad suficiente para su uso autónomo como alarma de deterioro bancario**. El problema de alerta requiere objetivos, umbrales y validaciones específicos.

9 Trazabilidad, software e inferencia

9.1 Implementación modular y pruebas

El procesamiento se organiza en módulos Python para extracción, panel, características y modelado. Se incluyen pruebas unitarias y de integración con `pytest`, además de revisión de calidad y formato con `Ruff`. Los notebooks documentan el razonamiento exploratorio y los experimentos; la inferencia final se ejecuta desde un módulo independiente.

9.2 MLflow y serialización

Se utilizó **MLflow 3.17.2** en un servidor local para almacenar parámetros, métricas y el pipeline final de scikit-learn. Se registraron **15 ejecuciones de optimización** en forma retrospectiva (cinco configuraciones por horizonte × tres horizontes) con las métricas obtenidas previamente; esto no significa que el seguimiento hubiera estado activo durante esos entrenamientos originales.

El modelo de un mes se guardó como `MorosidadRFDeltaH1` (versión 2 del registro local). Los horizontes de dos y tres meses usan archivos `JSON` con correcciones estacionales aprendidas

durante el entrenamiento seguro. La carga desde MLflow reprodujo las **276 predicciones** del horizonte de un mes, mientras que los artefactos estacionales reprodujeron otras **483**; total: **759 predicciones verificadas**.

Reproducibilidad por terceros. El repositorio aporta `environment.yml`, código, pruebas e instrucciones. Para reproducir exactamente los experimentos son necesarios los archivos Excel originales con sus hashes verificados; para ejecutar la inferencia de un mes también es necesario reconstruir o recuperar el modelo de un registro MLflow compatible.

10 Limitaciones y trabajos futuros

Disponibilidad de datos. La evaluación retrospectiva no verifica los retrasos de publicación de cada indicador. Se recomienda reproducirla con fechas de disponibilidad efectivas y reglas de información conocida en cada origen.

Heterogeneidad bancaria. Los errores no son homogéneos: algunas entidades presentan variabilidad mucho mayor y la mejora neta a un mes depende considerablemente de pocos bancos.

Eventos raros. La precisión de nivel no equivale a anticipación de shocks. Un desarrollo posterior deberá considerar calibración de alertas, objetivos específicos de clasificación de eventos, intervalos predictivos y métricas sensibles a episodios importantes.

Despliegue. El sistema no incluye aún un flujo operativo completo con recolección automática de datos, monitorización, gestión de versiones de nuevos informes y auditoría de fuentes.

11 Conclusiones

1. Se construyó y verificó un panel histórico de 23 bancos y 5.972 observaciones, preservando diferencias de cobertura y documentando casos financieros anómalos.
2. La validación temporal, la comparación contra referencias y la formulación por diferencias fueron decisivas para seleccionar las estrategias por horizonte sin basarse en Test.
3. El Random Forest delta flexible alcanzó **MAE de 0,2839 pp** a un mes en Test y redujo el error **8,19 %** respecto a persistencia estacional. En los horizontes de dos y tres meses se prefirió una referencia más simple.
4. La mejora de un mes no es uniforme entre bancos ni meses. Se constató un **recall de 21,7 %** para incrementos de al menos 0,5 pp: insuficiente para considerar el sistema un mecanismo autónomo de alerta.
5. MLflow, los artefactos estacionales, la inferencia separada de notebooks y la batería automatizada de pruebas mejoran la auditabilidad y muestran un flujo de Machine Learning de principio a fin.

En síntesis, la aportación principal no es solamente un resultado numérico, sino un proceso de investigación aplicado con comparación justa, prevención de filtraciones temporales, análisis de fallos y herramientas de reproducibilidad.

Fuentes y documentación

- Superintendencia de Bancos del Ecuador: `https://www.superbancos.gob.ec/`.
- Repositorio y documentación reproducible: Proyecto en GitHub.

- Notebooks fuente del proyecto: análisis exploratorio (01), ingeniería de variables (02), modelado (03) y experimentos delta (04).
- Documentación técnica: https://scikit-learn.org/, https://mlflow.org/docs/latest/.

A Procedencia de las figuras

Todas las visualizaciones de datos incluidas en este informe fueron extraídas de las salidas gráficas de los notebooks aportados, sin reconstruir ni modificar los valores representados. Se conservaron los archivos PNG y se renombraron para facilitar su inclusión en Overleaf. La figura del flujo de trabajo sí fue diseñada directamente con TikZ en este documento.

Notebook	Gráficas utilizadas
`01_analisis_exploratorio`	Cobertura, histograma de morosidad, diferencias entre bancos, BP Capital, evolución agregada, estacionalidad.
`04_experimentos_delta`	Comparación de modelos, ablación, validación anual, MAE de Test, ventaja mensual, comparación por institución, dispersión de deltas.

Documento de portafolio. Fecha: octubre de 2026. Las cifras corresponden exclusivamente a las salidas de los notebooks y a los experimentos compartidos para esta investigación.